

大纲


第一章 机器学习基础

第二章 Python与数据科学

第三章 线性回归算法


第四章 逻辑回归算法

第五章 K 最近邻算法



算法概述

1. 回归就是用一条曲线对数据点进行拟合，该曲线称为最佳拟合曲线，拟合过程称为回归。
2. 线性回归一般用来做连续值的预测，预测的结果是一个连续值。
3. 在训练学习样本时，不仅需要提供学习的特征向量x，还需要提供样本的实际结果(标记 Label)，因此属于监督学习。



算法流程

模型: $y = X\theta$, 其中 X 加入了常数行 1

$$\theta = (X^T X)^{-1} X^T y$$

数据量较小的时候，可以直接使用

算法步骤

数据量较大的时候，运用梯度下降法 Gradient Descent

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}]^2$$

设损失函数为

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_m x_m$$

$$\theta_j := \theta_j + \alpha [y^{(i)} - h_{\theta}(x^{(i)})] x_j^{(i)}$$

单个特征的迭代:

$$\theta_j := \theta_j + \alpha \sum_{i=1}^m [y^{(i)} - h_{\theta}(x^{(i)})] x_j^{(i)}$$

多特征的迭代:

- α为学习率或步长，需要人为指定，若过大则目标函数可能不收敛，若过小则收敛速度较慢。
- 一般会设置一个定值，当前后两次迭代差值小于该值时迭代结束。
- 需要人为设置的值
- 迭代的初始值同样需要人为设定。

算法实例 / 算法应用

#!/users/34680/python机器学习

$$y^* = \frac{y - E(y)}{s_y}$$

$$x_i^* = \frac{x_i - E(x_i)}{s_i}$$


算法改进与优化

偏最小二乘法 PLS (Partial Least Square Regression)

算法概述

KNN 算法的原理是，由某样本 K 个邻居的类别来推断出该样本的类别

更加适合类域的交叉或重叠较多的待分类样本




算法流程

算法步骤

算法概述

1. 是一种广义的线性回归分析方法
2. 在线性回归中得到预测值，然后将该值通过逻辑函数进行转换，这样就将预测值变成了概率值，再根据概率值实现分类
3. 主要应用领域：预测，判别，寻找影响结果的主要因素



算法流程

$$p(y|x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

单个样本后验概率

$$L(\theta) = \prod_{i=1}^m p(y_i | x_i; \theta)$$

$$\log L(\theta) = \sum_{i=1}^m [y_i \log(h_{\theta}(x_i)) + (1 - y_i) \log(1 - h_{\theta}(x_i))]$$

取对数

算法步骤

用梯度下降法优化 J(θ)，确定 θ

$$g(z) = \frac{1}{1 + e^{-z}}$$

sigmoid 函数

构建预测函数

$$z = \theta^T x$$

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

算法实例 / 算法应用

#!/users/34680/python机器学习

存在问题: log(h) 与 log(1-h) 常有一者接近0, 导致 runtime error

表 2-1 SciPy 前部分子功能			
模块	功能	模块	功能
scipy.cluster	矢量量化 / k-means	scipy.odr	正交距离回归
scipy.constants	物理和数学常数	scipy.optimize	优化
scipy.ffpack	傅里叶变换	scipy.signal	信号处理
scipy.integrate	积分程序	scipy.sparse	稀疏矩阵
scipy.interpolate	插值	scipy.special	空函数和特殊函数
scipy.io	数据输入输出	scipy.stats	统计
scipy.linalg	线性代数程序		
scipy.ndimage	图像图像处理		

KNN 算法在样本较少但典型性好的情况下分类效果较好